

به نام خدا

درس: علوم اعصاب محاسباتی مقدماتی

استاد: دکتر کربلایی

گزارش پروژه شماره ۲

سید محمد امین منصوری طهرانی

۹۴۱۰۵۱۷۴

علی شیرالی

۹۴۱۰۹۱۶۵

**توجه:** لطفاً برای اجرا شدن کد دیتاهای edf را در فولدری به نام EDF Data بگذارید یا در خط پنجم و هفدهم نام فولدری که فقط شامل آن‌هاست را جایگزین کنید.

## قسمت اول: آشنایی با مقاله پژوهش اصلی


۱. پژوهشگران این آزمایش ادعا می‌کنند که مدل‌های پیشین برای توصیف عمق خواب، بر مبنای پایه فیزیولوژیکی ایجاد سیگنال‌های slow wave که به خواب مربوطند نمی‌باشد و همین عامل باعث بروز نتایج غلط‌انداز در پژوهش‌های پیشین شده‌است مانند تفاوت دیده شده در عمق خواب زنان و مردان در حالی که نشان داده شده‌است (در مراجع مقاله) که این تفاوت عمق خواب واقعی نیست. یا تفاوت‌های اندازه‌گیری که ناشی از عوامل غیر اثرگذار بر خواب هستند مانند عوامل ناشی از آناتومی سر که در بیماران مختلف تفاوت‌های اندکی ایجاد می‌کند. هم‌چنین مهم‌تر از آن عدم تناسب نتایج بررسی حاصل از نظر خود افراد نسبت به کیفیت و عمق خواب با نتایج اندازه‌گیری با این مدل‌ها بود که این احتمال را تقویت می‌کند که پارامتر متناسب با خواب اندازه‌گیری نشده‌است. در این پژوهش بر مبنای مدل حلقه فیدبک که سیگنال‌های slow wave را تولید می‌کند، مقدار threshold به جای مواردی از قبیل توان کانال‌های مختلف، بر روی بهره حلقه فیدبک گذاشته شده و عمق خواب به این روش تعیین می‌شود و اشکالات ذکر شده رفع شده‌است. برای مثال نتایج پژوهش نشان داده که عمق خواب در شبی که داروی آرام‌بخش توسط بیمار مصرف شده‌است از هر دو روش اندازه‌گیری با مدل جدید و پرسش‌های پرسیده شده از شخص به نتیجه‌ی واحد بالا رفتن کیفیت خواب منجر شده‌است.

۲. در این آزمایش بهره حلقه فیدبک ایجاد کننده سیگنال slow wave و هم‌چنین SWP (توان سیگنال slow wave) برای ۲۲ بیمار که مقداری در خوابیدن مشکل داشتند طی دو شب اندازه‌گیری شده‌است. در هر دو شب ماده‌ای به بیماران داده می‌شود که فقط ماده مصرف شده در یک شب آرام‌بخش است (هدف بایاس نشدن ذهن اشخاص بوده‌است تا در پاسخ به سوالات ندانند کدام شب واقعا آرام‌بخش مصرف شده‌است). هدف این است که بررسی شود آیا این مدل: (۱) تغییرات عمق خواب که با SWP مشاهده شده و ناشی از طول خواب، سن و مصرف آرام‌بخش بوده‌است را تایید می‌کند یا خیر. (۲) اثرات ناشی از عوامل نامربوط به خواب (مانند جنسیت) را بازتاب می‌کند یا خیر.

۳. به این موارد به طور پراکنده در دو قسمت قبل اشاره شد. در مدل فیزیولوژیکی توصیف کننده سیگنال‌های slow wave بهره حلقه فیدبک توسط عمق خواب مدوله می‌شود بنابراین تخمین این بهره نزدیک‌ترین تخمین به واقعیت فیزیولوژیکی عمق خواب خواهد بود. هم‌چنین این این بهره تحت اثر عوامل نامربوط به خواب مانند عوامل مربوط به آناتومی نیست و ضمناً چون در حوزه زمان انجام می‌شود resolution زمانی آن به خاطر آنالیز حوزه فرکانس کاهش نمی‌یابد و نسبتاً real-time قابل اندازه‌گیری می‌شود.

۴. مدل انتخابی در این آزمایش سه ویژگی را دارا است: (۱) وجود حلقه فیدبکی که بهره آن متناسب با عمق خواب تعیین می‌شود. (۲) فعالیت‌های غیرقابل پیش‌بینی منابع دیگر نیز توسط ورودی سیستم باعث تاثیر در خروجی می‌شود. (۳) افزایش بهره فیدبک به افزایش SWP منجر می‌شود.

برای برقراری شرایط فوق مدل‌های مختلفی بر مبنای فیلتر low frequency در حلقه فیدبک، فرآیند تصادفی ورودی فیلتر و محل بهره حلقه فیدبک قابل ارائه است که در آزمایش آن مدلی انتخاب شده است که بیشترین شباهت را با سیگنال‌های EEG داشته است. مدل پیشنهادی به شکل زیر است:



شکل ۱

بهره حلقه فیدبک نشان دهنده اثر عمق خواب است (رابطه مستقیم). این حلقه سیگنالی تولید می کند که فیلتر  $G(f)$  فقط قسمت متناوب و ریتم دار یا معادلاً در این جا **slow wave** آن را جدا می کند. بهره حلقه مشخص می کند چه مقدار از این مولفه در آینده نزدیک در خروجی ادامه می یابد (در مقاله متناظر با بهره حلقه فیدبک به عنوان معیار عمق خواب ذکر شده است). این خروجی سپس از فیلتر پایین گذر عبور کرده و اثرات نامربوط به خواب با آن ترکیب شده و سپس سیگنال  $e(t)$  به عنوان سیگنال EEG ضبط می شود. در نهایت پس از محاسبات انجام شده نشان داده شده که این مدل به واقعیت بسیار شبیه بوده و فقط قله های توان در سیگنال وجود دارد (برخلاف مدل های دیگر به دره هایی در دیگر فرکانس ها منجر می شدند).


## قسمت دوم: آشنایی با دیتاست

۱. تابع **AnnotExtract** با گرفتن آدرس فایل **hypnogram** ماتریسی با دو سطر می دهد که سطر اول زمان اندازه گیری عمق خواب و سطر دوم عمق خواب به صورت کد شده است. تابع **edfread** فایل های **polysomnogram** را گرفته و هدر که شامل اطلاعات مربوط به داده های بیمار خاص است را به همراه داده های ضبط شده پروب های **FpzCz** و **PzOz** و **EOG** و **EMG** مربوط به زیرچانه و در سطر آخر خود **marker** نشان دهنده قابل استفاده بودن/نبودن داده را نشان می دهد. تابع **BPF** نیز طول فیلتر و فرکانس های قطع پایین و بالا و فرکانس نمونه برداری را گرفته پاسخ ضربه فیلتر متناظر را در خروجی بدست می دهد. تابع **FilterDFT** نیز به روش **DFT** کانولوشن را محاسبه می کند که از روش معمولی بسیار سریعتر است. سرعت این روش از مرتبه  $N \log(N)$  است در حالی که روش کانولوشن معمولی از مرتبه  $N^2$  است. از هر دو روش نیز استفاده کردیم و تفاوت فاحش روش دوم را مشاهده کردیم.

۲. علت خوب بودن بازه ۱۰ ثانیه ای این است که به نحوی می توان آن را ثابت زمانی تغییرات وضعیت خواب دانست. در این مدت مثلاً ممکن است شخص حرکت های کوچکی بکند یا در اثر تحریکی اندکی از عمق خواب او کم شود و می توان انتظار داشت مدت زمان چنین تغییرات محیطی در کمتر از ۱۰ ثانیه باشد لذا هر بازه ای به این طول یک وضعیت مشخص را می تواند نشان دهد.

### توضیح تابع **FeatureExtraction** :

در خروجی برای بررسی و تست کد، هدر و ماتریس ۵ سطری **record** نیز به همراه بردارهای **t** و **state** و ماتریس **X** گفته شده دریافت می شود. با تابع **AnnotExtract** و آدرس داده شده در ورودی تابع به فولدر حاوی هیپنوگرام که همان فولدر **Data** می باشد رفته و آن را می خواند. سپس مهم ترین قسمت این تابع که اثرات بسیار شدیدی در نتایج می گذارد یا همان حذف داده های پرت انجام می پذیرد. در سطر پنجم ماتریس **record** برای هر **subject** اعداد مختلفی قرار داد که اگر این اعداد ۱ یا ۲ باشند به معنی درست بودن داده های ضبط شده و در غیر این صورت به معنی غیرقابل استفاده بودن این داده ها بوده و باید حذف شوند. نکته مهمی نیز که باید به آن توجه کرد این است که فرکانس نمونه برداری این سطر یک دهم بقیه سطرهاست و این یعنی اگر به عنوان مثال در سطر پنجم ستون دهم عددهای نامربوط مانند ۳۰ یا ۳۰- دیده شد یعنی از داده ۹۱ تا ۱۰۰ خراب بوده و باید حذف شوند. صفر بودن عدد در این سطر نیز به معنی تمام شدن اندازه گیری است. با رسم آن ها برای **subject** اول این وضعیت را نشان می دهیم:



شکل ۲

مشخص است که با انبساط این شکل به میزان ۱۰ می‌توان داده‌های خراب و سالم را جدا کرد. در چند خط ابتدایی تابع این داده‌های پرت حذف می‌شوند. به جز این داده‌های پرت داده‌های پرتی که از محدوده ۵ برابر انحراف معیار توزیع داده‌ها خارج بودند نیز حذف می‌شوند. سپس مقداری داده دور ریخته می‌شود تا تعداد ستون‌های ماتریس record مضرب ۱۰ شوند. (برای سادگی برخی محاسبات بعدی) پارامتر فرکانس نمونه برداری معرفی شده و فیلترهای کانال‌های مختلف EEG بدست می‌آیند. برای سادگی برخی دیگر از محاسبات تعدادی کمتر از ۱۰۰۰ داده دور ریخته می‌شود (کمتر از ۱۰ ثانیه) تا تعداد ستون‌های این ماتریس مضرب ۱۰۰۰ شود یا معادلاً تعداد صحیح بازه ۱۰ ثانیه‌ای داشته باشیم. برای هر کدام از این بازه‌ها ابتدا درایه‌های بردارهای  $t$  و  $state$  بدست می‌آیند. سپس با اتمام این حلقه هر سطر ماتریس record، ۱۰۰۰ تا ۱۰۰۰ تا جدا شده و زیر هم قرار می‌گیرند. یعنی ۱۰۰۰ داده اول در ستون اول و ۱۰۰۰ داده دوم در ستون دوم و الی آخر. به این ترتیب برای وارد شدن به تابع FilterDFT آماده می‌شوند. (با توجه به کامنت‌های تابع FilterDFT) سپس برای هر بازه توان محاسبه می‌شود و نتیجه در ماتریس  $X$  به عنوان خروجی آخر تابع FeatureExtraction داده می‌شود.

۳. برای هر کدام از stage ها چند تصویر از قبل مشخص شدن وضعیت را بررسی می‌کنیم:

#### Stage W(wake):

در تصویر ۳ مشاهده می‌شود مولفه مربوط به حرکت چشم دامنه زیادی دارد که می‌تواند بیداری را نشان دهد. هم‌چنین مولفه FpzCz نیز غیرتناوبی و با دامنه نسبتاً زیاد ظاهر می‌شود. سیگنال PzOz با توان کم در این حالت دیده می‌شود. فرکانس سیگنال این دو کانال زیاد بوده که مشخص بیداری و در عین حال خواب REM نیز می‌باشد.

#### Stage 2(NREM):


در تصویر ۴ مشاهده می‌شود که توان تمام سیگنال‌ها کم است و فعالیت نوروها زیاد نیست. این مرحله خواب نسبتاً عمیق است.

#### Stage 4(NREM):


در تصویر ۵ در دو سیگنال اول الگوهای تناوبی مشاهده می‌شود و فعالیت نسبتاً زیاد است و با ادعای مقاله مبتنی بر slow wave microcontinuity سازگار است زیرا این حالت برای خواب عمیق پیش آمده است.

#### Stage R(REM):


در تصویر ۶ نیز مانند تصویر ۳ در دو سیگنال اول فرکانس زیاد است اما سیگنال مربوط به حرکت چشم توان کمی دارد. این دو تصویر نشان می‌دهند که سیگنال‌های خواب REM و Wakefulness به هم شباهت زیادی دارند و یادآور ویژگی paradoxical بودن خواب REM است.



شکل ۳




شکل ۴



شکل ۵





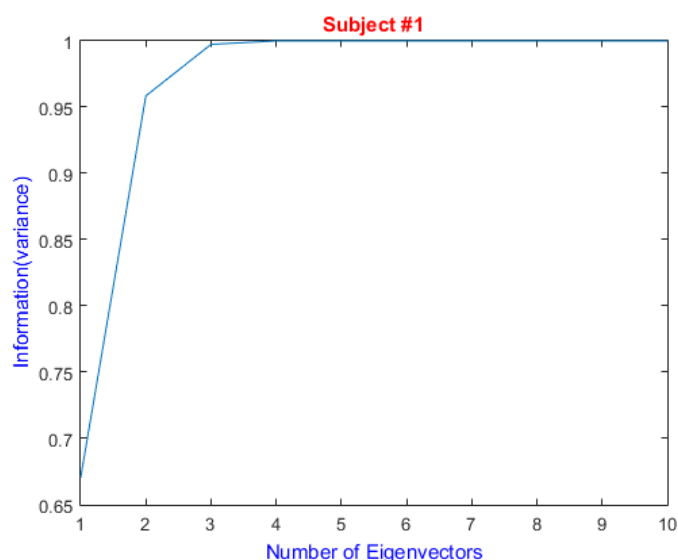
شکل ۶

## قسمت سوم: یافتن معیاری برای توصیف خواب مبتنی بر PCA

۱.  $\text{coeff}$  شامل بردارهای ویژه مشاهداتی است که به ورودی آن داده شده است (به ترتیب نزولی واریانس در راستای بردار ویژه). همان مشاهدات است که در دستگاهی جدید تعریف شده که بردارهای یک پایه آن در جهت بردارهای  $\text{coeff}$  هستند. Latent نیز واریانس داده‌ها در جهت هر بردار ویژه را بدست می‌دهد (به ترتیب نزولی).


در ابتدا داده‌های ما در فضایی با ۱۰ بعد قابل نمایش هستند. با استفاده از روش PCA بررسی می‌کنیم که کدام بردارهای ویژه واریانس و اطلاعات بیشتری را در خود ذخیره می‌کنند و دیگر بردارهای ویژه را دور می‌ریزیم. مثلاً اگر بیش از ۹۰ درصد واریانس یا معادلاً اطلاعات در ۳ بردار ویژه اول باشد می‌توانیم داده‌ها را در فضایی با ابعاد کمتر و در این‌جا ۳ بعدی نمایش دهیم که هم برای «مشاهده» امری مفید بوده و هم حجم محاسبات را کاهش داده و فقط مولفه‌های مهم‌تر را دخیل می‌کنیم.

۲. سه مولفه اول ۹۹/۷۴ درصد اطلاعات یا انرژی را شامل می‌شوند.



شکل ۷


۳. نقاط با توجه به state جدا شده و بر روی یک نمودار رسم می‌شوند. هم‌چنین برای داشتن نمایش و مشاهده تقسیم‌بندی از بقیه زوایا در نمودارهای دیگر نشان داده می‌شوند. این نتایج در تصویرهای زیر قابل مشاهده‌اند. برای مشاهده می‌توانید پس از اجرای کد آن‌را در زوایای مختلف برده و دسته‌بندی‌ها را مشاهده نمایید.



شکل ۸


۴. همان‌طور که مشاهده می‌شود مطابق انتظار پس از اعمال PCA داده‌ها در ۳ جهت اصلی پراکنده شده‌اند. (توجه مهم: برای نمایش بهتر مولفه اصلی را روی محور Z و مولفه با کمترین واریانس را روی محور اول گذاشتیم) بردار ویژه اول (محور Z) حامل مقدار زیادی اطلاعات است و بخش اعظم واریانس را تشکیل می‌دهد. (با نمودار سوال دوم همین بخش نیز سازگار است). state های مختلف با دقت زیادی از هم جدا نشده‌اند و از هر زاویه‌ای نگاه کنیم اطراف مبدأ به رنگ متفاوتی نشان داده می‌شود که به معنی تفاوت اندک در جهات دیگر است. با دستور set و آرگومان DataAspectRatio می‌توانیم نسبت داده‌ها را تغییر دهیم تا اثر دیگر مولفه‌ها نیز مشخص شود. این امکان در کد فراهم شده و با تغییر مولفه سوم بردار این آرگومان می‌توانید حالت‌های مختلف را ببینید.

(قرمز): وقتی از ناحیه یک هشتم اول فضای سه بعدی به شکل نگاه می‌کنیم بیشتر از همه رنگ قرمز در پایین نمودار وجود دارد که می‌توان از آن نتیجه گرفت مرحله اول خواب NREM دارای مولفه اول PCA نسبتاً زیادی بوده و مولفه دوم (محور Y) آن هم مقدار قابل توجهی دارد در حالیکه مقدار ناچیزی در جهت مولفه سوم (محور X) دارد. (شکل ۹)



شکل ۹


(سبز): در شکل زیر مشخص است که خواب عمیق (stage 4) دارای مولفه اول نسبتاً کم، مولفه دوم زیاد و مولفه سوم ناچیزی دارد.



شکل ۱۰


(زرد): هم‌چنین از شکل فوق مشخص است حالت عمق خواب متوسط یا stage 2 NREM در هر ۳ مولفه پراکنده شده است و به خوبی در ناحیه مشخصی قرار ندارد.

(بنفش): در شکل زیر مشخص است که خواب نسبتاً عمیق یا stage 3 NREM مولفه اول کم و مولفه دوم زیادی دارد و مولفه سوم آن ناچیز است اما از حالت عمیق (سبز) کمتر و قابل جداسازی است زیرا در این زاویه تنها رنگ بنفش دیده می‌شود.




شکل ۱۱

(آبی کم‌رنگ): در شکل ۱۲ مولفه سوم بیداری از سایر حالت‌ها بیشتر به نظر می‌رسد (چون در این زاویه خاص به این رنگ مشاهده می‌شود) و مولفه دوم مقدار نسبتاً کمی داشته و مولفه اول نیز در مقادیر پایین قرار دارد.



شکل ۱۲

(آبی پررنگ): در شکل زیر نیز که به خواب REM مربوط است می‌بینیم که مولفه اول برای این حالت از مقادیر کم تا زیاد را در بر گرفته و دو مولفه دیگر برای آن کم هستند. در مقادیر پایین مولفه اول، مولفه دوم کمی زیاد می‌شود.



شکل ۱۳

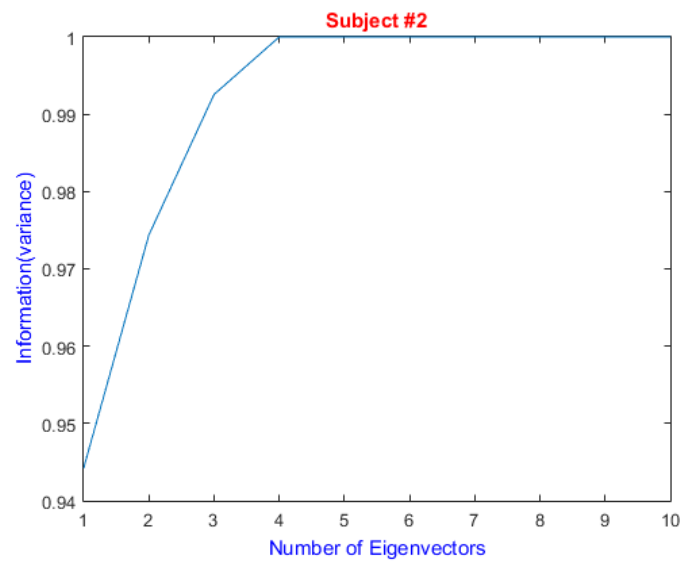
به عنوان نتیجه‌گیری نهایی می‌توان گفت مولفه‌های دوم و سوم با تفاوت‌های اندک این حالت‌ها را جدا می‌کنند. نقاط با مولفه اول نسبتاً بالاتر نشان‌دهنده عمق کمتر خواب (بیداری و REM و NREM stage 1 که معادل آبی کم‌رنگ و پررنگ و قرمز هستند) و نقاط با مولفه اول کمتر و مولفه دوم و سوم بیشتر عمق خواب بیشتر را نشان می‌دهند.

۵. سطرهای ماتریس  $\text{coeff}$  ضرایب متغیرها را نشان داده و ستون‌های آن بردار ویژه‌ها را به ترتیب نزولی واریانس آن‌ها. در اولین ستون یا بردار ویژه متغیر نهم بیشترین ضریب را دارد. یعنی در این مولفه متغیر نهم یا توان متوسط سیگنال EOG نقش اساسی را دارد. در ستون دوم متغیر اول یا توان متوسط باند دلتا در پروب FpzCz نقش اساسی دارد. در ستون سوم متغیر پنجم دارای ماکزیمم ضریب است که نشان‌دهنده توان متوسط همان کانال دلتا منتهی برای پروب PzOz است. به این ترتیب با ترکیب این نتایج با پاسخ سوال قسمت قبل به نتیجه زیر می‌رسیم:


در حالت‌های با عمق کمتر خواب که مربوط به بیداری و REM و NREM stage 1 هستند انتظار داریم هنوز چشم دارای حرکاتی باشد و مولفه اول که آن‌هم نشان‌دهنده توان حرکت چشم است در این حالت‌ها بزرگ است. هم‌چنین هرچه توان سیگنال کانال دلتا در پروب PzOz بیشتر باشد عمق خواب بیشتر است. خواب REM نیز به میزان اندکی با توان متوسط کانال دلتای FpzCz متناظر است. این که کانال دلتا در خواب اثر بیشتری دارد بازتاب‌کننده اثرگذاری slow wave (فرکانس کانال دلتا که صفر تا ۴ هرتز است) در عمق خواب است.

۶. برای مشاهده نتیجه برای بقیه subject ها لطفا در کد شماره subNumber را تغییر دهید.


برای subject #2: سه مولفه اول ۹۹/۲۶ درصد اطلاعات یا انرژی را شامل می‌شوند.




شکل ۱۴



شکل ۱۵



شکل ۱۶



شکل ۱۷

(قرمز): وقتی از ناحیه یک هشتم اول فضای سه بعدی به شکل نگاه می‌کنیم (شکل ۱۵) بیشتر از همه رنگ قرمز در پایین نمودار وجود دارد که می‌توان از آن نتیجه گرفت مرحله اول خواب NREM دارای مولفه اول PCA نسبتاً زیادی بوده و مولفه دوم (محور Y) آن هم مقدار قابل توجهی دارد.

(سبز): در شکل ۱۷ مشخص است که خواب عمیق (stage 4) دارای مولفه اول نسبتاً کم، مولفه دوم زیاد و مولفه سوم ناچیزی دارد.

(زرد): هم‌چنین از شکل فوق (۱۷) و ۲۰ مشخص است حالت عمق خواب متوسط یا stage 2 NREM در هر ۳ مولفه پراکنده شده است ولی تمرکز نسبی در مرکز مختصات دارد. اما مولفه اول آن نسبتاً زیاد است.


(بنفش): در همان شکل ۱۷ و ۲۱ و ۲۲ مشخص است که خواب نسبتاً عمیق یا stage 3 NREM مولفه اول کم و مولفه دوم بیشتری دارد اما از خواب عمیق (مرحله ۴-سبز) کمتر است.

(آبی کم‌رنگ): تمرکز ویژه‌ای برای این حالت در شکل‌ها دیده نمی‌شود و تنها به نظر می‌رسد (شکل ۱۸) همه مولفه‌ها را به مقدار کمی داراست.


(آبی پررنگ): در شکل ۱۹ مشاهده می‌شود برای این حالت که به خواب REM مربوط است، مولفه اول از مقادیر کم تا زیاد را در بر گرفته و دو مولفه دیگر برای آن کم هستند.

به عنوان نتیجه‌گیری نهایی می‌توان گفت مولفه‌های دوم و سوم با تفاوت‌های اندک این حالت‌ها را جدا می‌کنند. نقاط با مولفه اول نسبتاً بالاتر نشان‌دهنده عمق کمتر خواب (بیداری و REM و NREM stage 1 که معادل آبی کم‌رنگ و پررنگ و قرمز هستند) و نقاط با مولفه اول کمتر و مولفه دوم بیشتر عمق خواب بیشتر را نشان می‌دهند.







شکل ۱۸




شکل ۱۹



شکل ۲۰



شکل ۲۱




شکل ۲۲

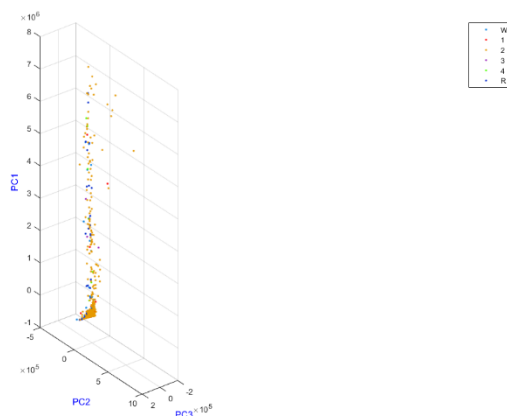
در اولین ستون یا بردار ویژه متغیر نهم بیشترین ضریب را دارد. یعنی در این مولفه متغیر نهم یا توان متوسط سیگنال EOG نقش اساسی را دارد. در ستون دوم متغیر اول یا توان متوسط باند دلتا در پروب FpzCz نقش اساسی دارد. در ستون سوم متغیر دهم دارای ماکزیمم ضریب است که نشان‌دهنده توان متوسط EMG است. به این ترتیب با ترکیب این نتایج با نتیجه قبلی به نتیجه زیر می‌رسیم:

در حالت‌های با عمق کمتر خواب که مربوط به بیداری و REM و NREM stage 1 هستند انتظار داریم هنوز چشم دارای حرکاتی باشد و مولفه اول که آن‌هم نشان‌دهنده توان حرکت چشم است در این حالت‌ها بزرگ است. همچنین هرچه توان سیگنال کانال دلتا در پروب FpzCz بیشتر باشد عمق خواب بیشتر است. این که کانال دلتا در خواب اثر بیشتری دارد بازتاب‌کننده اثرگذاری slow wave (فرکانس کانال دلتا که صفر تا ۴ هرتز است) در عمق خواب است.


برای subject #3: سه مولفه اول ۹۹/۹۹ درصد اطلاعات یا انرژی را شامل می‌شوند. اما از شکل زیر مشخص است که همان بردار ویژه اول تقریباً تمام اطلاعات و واریانس را شامل می‌شود و انتظار داریم در تصاویر سه بعدی تمام داده‌ها حول یک محور باشند.



شکل ۲۳



شکل ۲۴



شکل ۲۵

(قرمز): برای این رنگ تمرکز خاصی در ناحیه‌ای از فضا مشاهده نمی‌شود و نمی‌توان قاعده‌ای برای آن ارائه داد.

(سبز): با دقت در شکل‌های ۲۵ و ۲۷ و ۲۸ و ۳۰ می‌توان پی برد که خواب عمیق (stage 4) دارای مولفه اول نسبتاً کم، مولفه دوم کمتر از حالت زرد و مولفه سوم زیادی دارد.


(زرد): هم‌چنین از اشکال فوق مشخص است برای حالت عمق خواب متوسط یا stage 2 NREM مولفه اول از مقادیر زیاد تا کم تغییر کرده ولی عمدتاً مولفه سوم زیادی دارند. مولفه دوم آن‌ها نیز به مقدار جزئی بیشتر از حالت سبز و باعث می‌شود به این رنگ دیده شود.

(بنفش): مانند رنگ قرمز تمرکز خاصی در ناحیه‌ای از فضا مشاهده نمی‌شود و نمی‌توان قاعده‌ای برای آن ارائه داد.


(آبی کم‌رنگ): تنها می‌توان گفت مولفه سوم آن زیاد است.

(آبی پررنگ): در شکل ۲۸ می‌بینیم که مولفه اول برای این حالت از مقادیر کم تا زیاد را در بر گرفته و دو مولفه دیگر برای آن کم هستند.


به عنوان نتیجه‌گیری نهایی می‌توان گفت مولف نقاط با مولفه اول نسبتاً بالاتر نشان‌دهنده عمق بیشتر خواب (NREM stage 2 و 4 NREM که معادل زرد و سبز هستند) و نقاط با مولفه اول کمتر و مولفه سوم بیشتر عمق خواب کمتر را نشان می‌دهند.




شکل ۲۶




شکل ۲۷



شکل ۲۸



شکل ۲۹

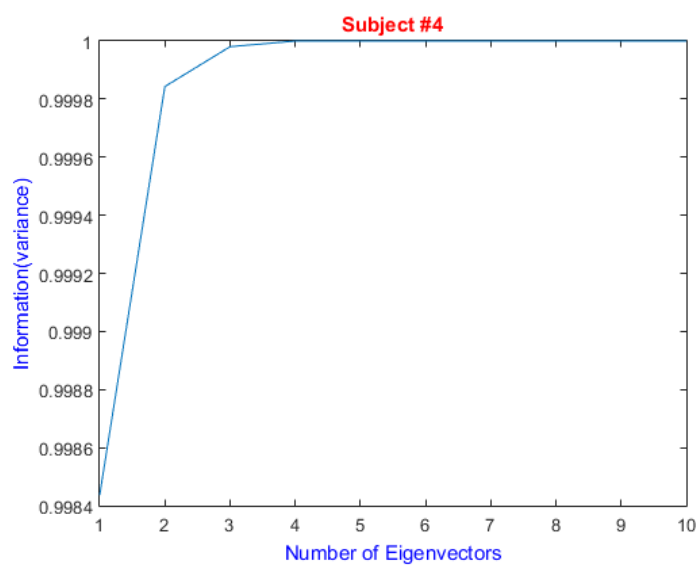


شکل ۳۰


در اولین ستون یا بردار ویژه متغیر نهم بیشترین ضریب را دارد. یعنی در این مولفه متغیر پنجم یا توان متوسط سیگنال کانال دلتا برای پروب PzOz نقش اساسی را دارد. در ستون دوم متغیر ششم یا توان متوسط باند تتا برای همان پروب قبلی نقش اساسی دارد. در ستون سوم متغیر نهم دارای ماکزیمم ضریب است که نشان‌دهنده توان متوسط EOG است. به این ترتیب با ترکیب این نتایج با نتیجه قبلی به نتیجه زیر می‌رسیم:

مانند قبل در حالت‌های با عمق کمتر خواب که مربوط به بیداری و REM و NREM stage 1 هستند انتظار داریم هنوز چشم دارای حرکاتی باشد و مولفه اول که آن‌هم نشان‌دهنده توان حرکت چشم است در این حالت‌ها بزرگ است و با زیاد بودن مولفه سوم آن‌ها که بحث شد سازگار است. هم‌چنین هرچه توان سیگنال کانال دلتا در پروب PzOz بیشتر باشد عمق خواب بیشتر است که با زیاد بودن مولفه اول متناظر و سازگار است. باز هم این مشاهده که کانال دلتا در خواب اثر بیشتری دارد و بازتاب‌کننده اثرگذاری slow wave (فرکانس کانال دلتا که صفر تا ۴ هرتز است) در عمق خواب است تایید می‌شود.


برای subject #4: سه مولفه اول با تقریب بسیار خوبی ۱۰۰ درصد اطلاعات یا انرژی را شامل می‌شوند. اما از شکل زیر مشخص است که همان بردار ویژه اول تقریباً تمام اطلاعات و واریانس را شامل می‌شود و انتظار داریم در تصاویر سه بعدی تمام داده‌ها حول یک محور باشند.




شکل ۳۱



شکل ۳۲



شکل ۳۳



شکل ۳۴

(قرمز): باز هم ناحیه خاصی را نمی‌توان به این حالت اختصاص داد و پراکندگی زیادی دارد. تنها می‌توان گفت احتمالاً مولفه اول آن نسبتاً زیاد است. (شکل ۳۸)

(سبز): در شکل ۳۵ و ۳۶ مشخص است که خواب عمیق (stage 4) دارای مولفه اول کم تا زیاد، مولفه دوم زیاد و مولفه سوم ناچیزی دارد.

(زرد): هم‌چنین از اشکال فوق مشخص است حالت عمق خواب متوسط یا stage 2 NREM در هر ۳ مولفه پراکنده شده است اما با بزرگنمایی ناحیه‌ای که همه حالت‌ها در آن جا هستند مشاهده می‌شود (شکل ۳۵ و ۳۶ و ۳۸) که مولفه اول برای این حالت بسیار زیاد است و مولفه دوم آن از حالت سبز کمتر است.


(بنفش): در شکل ۳۶ و ۳۸ دیده می‌شود که در این حالت مولفه اول زیاد است.

(آبی کم‌رنگ): در شکل ۳۴ مولفه اول بیداری مقدار زیادتری از حالت‌های قبل است.




(آبی پررنگ): در همان شکل ۳۴ می‌بینیم که مولفه اول برای این حالت از مقادیر کم تا زیاد را در برگرفته و دو مولفه دیگر برای آن کم هستند.


به عنوان نتیجه‌گیری نهایی می‌توان گفت مولفه‌ی دوم با تفاوت‌های اندک این حالت‌ها را جدا می‌کند. نقاط با مولفه اول نسبتاً بالاتر نشان‌دهنده عمق کمتر خواب (بیداری و REM و NREM stage 1 که معادل آبی کم‌رنگ و پررنگ و قرمز هستند) و نقاط با مولفه اول کمتر و مولفه دوم بیشتر عمق خواب بیشتر را نشان می‌دهند.




شکل ۳۵



شکل ۳۶



شکل ۳۷




شکل ۳۸


(کاملاً مانند subject 1) در اولین ستون یا بردار ویژه متغیر نهم بیشترین ضریب را دارد. یعنی در این مولفه متغیر نهم یا توان متوسط سیگنال EOG نقش اساسی را دارد. در ستون دوم متغیر اول یا توان متوسط باند دلتا در پروب FpzCz نقش اساسی دارد. در ستون سوم متغیر پنجم دارای ماکزیمم ضریب است که نشان‌دهنده توان متوسط همان کانال دلتا منتهی برای پروب PzOz است. به این ترتیب با ترکیب این نتایج با نتیجه قبلی به نتیجه زیر می‌رسیم:

در حالت‌های با عمق کمتر خواب که مربوط به بیداری و REM و NREM stage 1 هستند انتظار داریم هنوز چشم دارای حرکتی باشد و مولفه اول که آن‌هم نشان‌دهنده توان حرکت چشم است در این حالت‌ها بزرگ است. هم‌چنین هرچه توان سیگنال کانال دلتا در پروب FpzCz بیشتر باشد عمق خواب بیشتر است. هنوز هم این‌که کانال دلتا در خواب اثر بیشتری دارد ما را به اثر گذاری slow wave در عمق خواب می‌رساند.


برای subject #5: سه مولفه اول ۹۹/۸۳ درصد اطلاعات یا انرژی را شامل می‌شوند. اما از شکل زیر مشخص است که همان بردار ویژه اول درصد زیادی از تمام اطلاعات و واریانس را شامل می‌شود و انتظار داریم در تصاویر سه بعدی اکثر داده‌ها حول یک محور باشند.



شکل ۳۹



شکل ۴۰



شکل ۴۱

(قرمز): با توجه به شکل ۴۳ مولفه اول آن کم و مولفه دوم آن نسبتاً زیاد است.

(سبز): به نظر می‌رسد تمرکز خاصی برای آن‌ها وجود ندارد.


(زرد): هم‌چنین از شکل ۴۲ مشخص است حالت عمق خواب متوسط یا stage 2 NREM مولفه اول و سوم کم و مولفه دوم زیادتری دارد.

(بنفش): باز هم تمرکز زیادی دیده نمی‌شود.


(آبی کم‌رنگ): در شکل ۴۳ و ۴۴ مشخص است که بیشتر این نقطه‌ها در جهت مولفه دوم هستند.

(آبی پررنگ): مانند آبی کم‌رنگ.


به عنوان نتیجه‌گیری نهایی می‌توان گفت مولفه‌های دوم و اول با تفاوت‌های اندک این حالت‌ها را جدا می‌کنند. نقاط با مولفه دوم نسبتاً بالاتر نشان‌دهنده عمق کمتر خواب (بیداری و REM و NREM stage 1 که معادل آبی کم‌رنگ و پررنگ و قرمز هستند) و نقاط با مولفه دوم کمتر و مولفه سوم کمتر عمق خواب بیشتر را نشان می‌دهند.



شکل ۴۲



شکل ۴۳



شکل ۴۴

در اولین بردار ویژه متغیر پنجم بیشترین ضریب را دارد. یعنی در این مولفه متغیر پنجم یا توان متوسط سیگنال کانال دلتا برای پروب PzOz نقش اساسی را دارد. در ستون دوم متغیر نهم یا توان متوسط EOG نقش اساسی دارد. در ستون سوم

متغیر دهم دارای ماکزیمم ضریب است که نشان‌دهنده توان متوسط EMG است. به این ترتیب با ترکیب این نتایج با نتیجه قبلی به نتیجه زیر می‌رسیم:

در حالت‌های با عمق کمتر خواب که مربوط به بیداری و REM و NREM stage 1 هستند انتظار داریم هنوز چشم‌داری حرکاتی باشد و مولفه اول که آن‌هم نشان‌دهنده توان حرکت چشم است در این حالت‌ها بزرگ است. در این مورد رابطه خوبی مانند حالت‌های قبل بین توان کانال دلتا و عمق خواب بیشتر مشاهده نشد.

۷. با توجه به کلیه نتیجه‌های قسمت‌های قبل می‌توان انتظار داشت که عمق خواب‌های کم با توان سیگنال EOG متناسب باشد و می‌توان این حالت را با این سیگنال تشخیص داد. در اکثر موارد حالت خواب عمیق با بیشتر بودن توان متوسط کانال دلتا متناظر بود و این می‌تواند فرضیه تناسب عمق خواب با دامنه یا توان slow wave را برایمان تقویت کند. سیگنال EMG با وجود این که جزو محورهای PCA بود، در تشخیص و دسته‌بندی کمک چندانی به ما نکرد بنابراین احتمالاً می‌توان از آن در آزمایش‌های بعدی صرف‌نظر نمود و یا به عنوان مثال پارامتر دیگری که حدس می‌زنیم در خواب موثر باشد (مثل میکروپویوستگی یا توان نسبی کانال دلتا) به جای آن محور قرار داد. همچنین با توجه به این که در مواردی نیز توان کانال دلتا به خوبی امکان دسته‌بندی را فراهم نکرد، می‌توان به این فکر افتاد که شاید این معیار از یک subject به subject دیگر دستخوش تغییر شود اما چون حدس می‌زنیم این پارامتر با خواب تناسب دارد (مشاهده در موارد زیاد) فقط اندکی آن را بهبود می‌دهیم و به عنوان مثال به جای توان متوسط کانال دلتا می‌توانیم از معیار میکروپویوستگی که در مقاله ذکر شده برای این سیگنال استفاده کنیم یا مقدار آن را بر کمیت مناسبی در هر subject تقسیم کنیم تا نرمالایز شده و احتمالاً دسته‌بندی بهتر و مطلوب‌تری را بدست آوریم.

۸.

## قسمت چهارم: یافتن معیاری برای عمق خواب مبتنی بر Linear Regression

۱. در این قسمت صرفاً با state های 1 تا 4 از سابجکت اول کار می‌کنیم. در ادامه مدلی خطی از فیچرهایی که قبلاً برای این سابجکت بدست آورده‌ایم (خروجی FeatureExtraction) به state خواب fit می‌کنیم (با ادبیات MATLAB، فیچرها predictor و state، response خواهند بود). این کار را برای فیچره‌های نرمالایز شده نیز تکرار می‌کنیم (در ادامه علت آن توضیح داده خواهد شد).

اکنون می‌خواهیم به این پرسش پاسخ دهیم که کدام فیچرها "مهمتر" هستند؟ پاسخ به این سوال کار آسانی نیست و شاید تا حدی به تعبیر ما از اهمیت برگردد اما سعی می‌کنیم دو معیار منطقی برای سنجش میزان اهمیت هر فیچر ارائه دهیم و نتایج را مقایسه کنیم.

معیار اول، ضرایب متناظر با هر فیچر در مدل خطی فیت شده بر داده‌های نرمالایز شده است. لازم به ذکر است استفاده از ضرایب مدل بدون نرمالایز کردن داده‌ها بی‌معنی است چرا که این ضرایب به واریانس فیچر حساس است که نمی‌تواند نشانه‌ای در تشخیص اهمیت آن بر محاسبه response باشد. البته مثبت و منفی بودن ضرایب همچنان نشان‌دهنده افزایش یا کاهش بودن تاثیر است.

معیار دوم، میزان افزایشی است که در R-squared مدل می‌بینیم وقتی فیچر مدنظر را به بقیه فیچرها اضافه می‌کنیم (توضیح بیشتر راجع به R-squared در سوال بعد). تعبیر این معیار این است که این فیچر جدید چه مقدار واریانس جدید را می‌تواند توضیح دهد درحالی که بقیه فیچرها قابل به توضیح آن نبودند.

در ادامه فیچرهای مرتب شده به ترتیب اهمیت و effect size آن‌ها با هر دو معیار گزارش شده است (شماره‌گذاری فیچرها با شماره‌گذاری صورت سوال در تشکیل ماتریس X مطابقت دارد).

```
----- R2 effect size (same for raw or normalized) -----
var    eff-size
x6      0.026
x10     0.006
x2      0.003
x8      0.003
x4      0.002
x7      0.000
x9      0.000
x3      0.000
x5      0.000
x1      0.000

----- coeff effect size for normalized data -----
var    eff-size
x6      0.032
x8     -0.013
x7      0.008
x4     -0.004
x2      0.003
x3     -0.002
x10     -0.000
x5      0.000
x9      0.000
x1      0.000
```

نتایج دو معیار نسبتاً همخوانی دارد به نظر می‌رسد سیگنال‌های EEG در تشخیص عمق خواب اهمیت بیشتری دارند (به خصوص باند تتا از پروب Oz).

اما از دیگر خروجی‌های fitlm، p-value های متناظر با هر predictor، و p-value متناظر با کل مدل است. p-value برای هر predictor متناظر با t-test روی صفر نبودن آن predictor است که از estimate/SE محاسبه می‌شود (وارد جزئیات چگونگی محاسبه SE نمی‌شویم!). تعبیر آن نیز این است که این ضریب تا چه اندازه به طور معنی داری از صفر دور است. از این شاخص می‌توان برای تشخیص وارد کردن یا نکردن فیچری استفاده کرد اما شاید برای تشخیص اهمیت مناسب نباشد (از این کار در literature نهی شده‌ایم!). در ادامه p-value های منتظر با ضرایب گزارش شده‌اند.

	Estimate	SE	tStat	pValue
(Intercept)	1.8815	0.035315	53.279	0
x1	9.1195e-07	4.0912e-06	0.22291	0.82363
x2	0.0031262	0.0010637	2.939	0.0033257
x3	-0.001526	0.0027227	-0.56046	0.57522
x4	-0.0042116	0.0017633	-2.3884	0.017002
x5	3.9232e-06	1.0494e-05	0.37386	0.70855
x6	0.031961	0.0039476	8.0964	9.1009e-16
x7	0.0078478	0.0082977	0.94578	0.34436
x8	-0.013273	0.004645	-2.8575	0.0043086
x9	2.3379e-06	2.7662e-06	0.84517	0.3981
x10	-0.00012163	3.2557e-05	-3.736	0.00019151

به نظر می‌رسد x1,x3,x5,x7,x9 (متناظر با کانال‌های دلتا و آلفای هر دو الکتروود و EOG) می‌توانند از مدل حذف شوند (البته در شرایط خاص وابستگی خطی دو فیچر به هم p-value هر دو کوچک می‌شود و حذف باید با دقت انجام گیرد). این فیچرها قبلاً هم با هر دو معیار به عنوان فیچرهایی کم اهمیت تشخیص داده شده بودند.

اما p-value ای که به کل مدل نسبت داده می‌شود خروجی F-test بین مدل فیت شده و مدلی با فقط یک ثابت. F-test بین دو مدل که به ترتیب  $p_1$  و  $p_2$  پارامتر دارند با  $n$  داده، از رابطه

$$F = \frac{RSS_1 - RSS_2}{\frac{RSS_2}{n - p_2}}$$

محاسبه می‌شود که  $RSS$ ، residual sum of squares است.  $F$  بزرگ یعنی فرض  $null$  رد شده و مدل معنی‌دار است که در مدل ما هم همینطور است.

۲. R-squared برای توصیف این که چقدر predictor ها می‌توانند واریانس response را پوشش بدهند به کار می‌رود. فرض کنید  $n$  داده داریم  $(y_i)$  و خروجی مدل ما برای این نقاط  $f_i$  باشد. R-squared این‌گونه تعریف می‌شود:


$$R^2 = 1 - (\sum_i (y_i - \bar{y})^2) / (\sum_i (y_i - f_i)^2)$$

R-squared برای مدل ما 0.0817 که به نظر نمی‌رسد از این نظر مدل خوبی داشته باشیم.


۳. به نظر می‌رسد این مدل بیشتر برای توصیف مسئله مناسب باشد چرا که همانطور که شاخص R-squared نشان می‌دهد مدل به خوبی نمی‌تواند روی داده‌ها فیت شود اما در تعیین رابطه نسبی فیچرها و تاثیرگذاری‌شان همچنان موثر است.

۴. توزیع پاسخ پیش‌بینی شده‌ی مدل در همان نقاط training در شکل زیر رسم شده است. به نظر می‌رسد توزیع‌های مربوط به هر stage تا حدی از یکدیگر قابل تفکیک باشند که نشانه خوبی است.





۵. اینبار تلاش می‌کنیم به وضعیت‌های REM و بیداری نیز عمق خواب نسبت دهیم و بدین منظور از مقادیر از مدل خطی‌ای که بدست آوردیم استفاده می‌کنیم. توزیع مقادیر پیش‌بینی شده در ادامه قابل ملاحظه است. به نظر نمی‌رسد دو توزیع تفاوت معناداری داشته باشند و این احتمالاً یعنی نسبت دادن عمق خوابی به REM و بیداری با این مدل معنی‌دار نیست.



۶. بخش‌های قبل را برای سایر سابجکت‌ها تکرار می‌کنیم. نتایج در ادامه گزارش شده است. همانطور که ملاحظه می‌گردد نتایج یکسان نیست و تفاوت‌ها ذکر گشته است.

مقایسه نتایج سوال اول و دوم:

subject	Most important features	Low p-value features	R-squared
1	x6,x8,x2	x1,x3,x5,x7,x9	0.0817
2	x8,x6,x5	x4,x7,x10	0.425
3	x3,x2,x9	x6,x7,x8	0.155
4	x6,x8,x2	x7	0.398
5	x2,x9,x1	x5,x6,x7,x8,x10	0.0455



به نظر می‌رسد مدل خطی به ساجکتها اول و پنجم به خوبی بقیه فیت نمی‌شود. فیچرهای مهم برای ساجکت‌های اول و دوم و سوم و چهارم یکسانی است در حالی که برای دو ساجکت دیگر فیچرهای مهم ساجکت‌های قبلی p-value های کمی دارند و می‌توانند حذف شوند که نتیجه عجیبی است!







مقایسه تقریبی نتایج سوال چهارم و پنجم:

subject	How well different states fitted values distribution can be distinguished?	Predicted value for REM and WAKE states are meaningful?
1	Good	no
2	Very good	yes
3	Good	no
4	Very Good	yes
5	bad	no

همانطور که انتظار داشتیم هرچه مدل بهتر فیت شود (مثلا با شاخص R-squared) توزیع مقادیر پیش‌بینی شده برای state های مختلف راحت‌تر جدا می‌شوند. همچنین برای این مدلها نسبت دادن عددی به REM و WAKE می‌تواند با معنی باشد.

نتایج سوال چهارم و پنجم:





۷. در این بخش سعی کردیم با در نظر گرفتن عمق خواب به عنوان متغیری پیوسته، مدلی خطی از فیچرهایی که در بخش‌های قبلی بدست آورده بودیم به عمق خواب بیابیم. این مدل‌ها بسته با سابجکت می‌توانست تا حدی واریانس عمق خواب را دربرگیرد اما ما سعی کردیم از رابطه نسبی فیچرها در توصیف مسئله و اهمیت هر متغیر به state خواب استفاده کنیم. در ادامه با بررسی توزیع‌های پیش‌بینی شده برای عمق خواب state‌های مختلف مشاهده کردیم در مدل‌هایی که خوب فیت شده‌اند مطابق انتظار توزیع‌ها متمایز اند. همچنین از مدل خطی‌مان برای نسبت دادن عددی به دو وضعیت REM و WAKE استفاده کردیم که در برخی سابجکت‌ها ظاهراً معنی‌دار بود. نتایج این بخش و فیچرهایی تاثیرگذاری که بدست آوردیم با بخش قبل سازگاری ندارد که لازم است بیشتر بررسی‌اش کنیم!

## قسمت پنجم: سوال دلخواه


ابتدا قصد داریم فیچرهای جدیدی به مسئله اضافه کنیم و تاثیرگذاری آنها را در مقایسه با فیچرهای قبلی بررسی کنیم. آن طور که با بررسی چشمی مشهود است (و مقاله هم به آن اشاره کرده است) در خواب عمیق نوسان منظمی در باندهای فرکانس پایین EEG دیده می شود. برای اندازه گیری کمی وجود نوسان منظم، در هر باند در بازه های 10 ثانیه ای از سیگنال  $fft$  گرفته و نسبت مجذور بزرگترین دامنه آن را به توان سیگنال در آن بازه حساب می کنیم. هر چه این عدد بزرگتر باشد تقریباً انتظار داریم توان بیشتری از سیگنال در یک دامنه خاص متمرکز شده باشد و سیگنال تمیزتر نوسان کند. با فیچرهای جدید بخش های قبل را تکرار می کنیم. نتایج در ادامه ارائه شده است.

subject	New most important features	Previous R-squared	New R-squared
1	x6,x10,x8	0.0817	0.0855
2	x8,x6,x5	0.425	0.454
3	x2,x9,x11	0.155	0.198
4	x6,x8,x2	0.398	0.416
5	x15	0.0455	0.112

به نظر می رسد فیچرهای جدید آنطور که انتظار داشتیم فیچرها خوبی نیستند. تنها در مورد آخر فیچر جدید در بالابردن  $R$ -squared و مقایسه نسبی با بقیه فیچرها موفق بوده است!

یکی دیگر از مواردی که می توان آن را بررسی کرد این است که آیا با خوشه بندی می توانیم به دسته بندی های مشاهده به وسیله رنگ ها دست یابیم یا خیر. بنابراین روش کار ما بدین صورت است که داده ها را با دستور  $kmeans$  خوشه بندی کرده و در مرحله بعد مشخص می کنیم هر خوشه ای که  $kmeans$  داده معادل کدام خوشه (حالت خواب) ما است. عملیات تناظر برقرار کردن بین خوشه های  $kmeans$  و دسته های واقعی به روش های مختلفی می تواند صورت گیرد و ما ۳ حالت آن را بررسی می کنیم. پس از برقرار کردن تناظر (با هر یک از سه روش زیر) نتیجه دسته بندی مان را در فضای سه بعدی رسم می کنیم تا با دسته بندی بدست آمده با  $PCA$  مقایسه کنیم.

روش اول یافتن حالت خواب متناظر با شماره خوشه خروجی از  $kmeans$ : در این روش برای هر یک از ۶ اندیس خوشه که  $kmeans$  می دهد، تعداد مشاهده هایی که به هریک از حالت های خواب مربوط هستند را حساب می کنیم و بر تعداد کل مشاهده هایی که به آن حالت خواب مربوط هستند تقسیم می کنیم. برای روشن تر شدن موضوع مثالی می زنیم. فرض کنیم می خواهیم ببینیم خوشه شماره یک  $kmeans$  به کدام حالت خواب بیشتر مربوط است. از مشاهده هایی که در این خوشه قرار گرفته اند تعداد آن هایی که به هر یک از شش حالت خواب مربوط اند را محاسبه می کنیم و به تعداد کل مشاهده های مربوط به آن حالت خواب تقسیم می کنیم. یکی از این شش عدد از بقیه بزرگتر بود و می توان انتظار داشت این خوشه به آن حالت خواب مربوط است. نتیجه این کار در زیر آورده شده است. مشاهده می شود با خوشه بندی هم به نتیجه مطلوبی نمی رسیم! معیار فاصله خوشه ها را تغییر دادیم و باز هم نتیجه نداد! (حتی تناظر یک به یک بین خوشه ها برقرار نیست)



روش دوم: فاصله هر خوشه را تا میانگین دسته‌هایی که برای حالت‌های مختلف خواب داریم تعیین می‌کنیم (فاصله هر خوشه را تا آن نقطه فاصله میانگین نقاط خوشه تا آن نقطه تعریف می‌کنیم). و فاصله این خوشه با هر دسته‌ای کمتر شد آن حالت خواب را به آن نسبت می‌دهیم.

روش سوم: **prior probability** را نیز وارد می‌کنیم. به عنوان مثال در خوشه اول **kmeans** تعداد  $m$  مشاهده از کل  $n$  مشاهداتی که در این خوشه قرار دارند به حالت خواب  $a$  مربوط شده است. نسبت  $\frac{m}{n}$  **prior-probability(a)** هر چقدر بیشتر باشد نشان می‌دهد این خوشه به احتمال زیاد به حالت خواب  $a$  مربوط است. (احتمال قبلی نیز با تقسیم تعداد مشاهدات خواب  $a$  به کل مشاهدات به دست می‌آید). برای هر شماره خوشه، این نسبت را برای همه حالات خواب امتحان می‌کنیم و حالتی که این مقدار برای آن ماکزیمم شد را به عنوان حالت متناظر این شماره خوشه در نظر می‌گیریم.

برای دو روش فوق نیز خوشه‌بندی به نتیجه مناسبی نرسید و از آوردن آن‌ها خودداری می‌کنیم.

یک سوال دیگر می‌تواند این باشد که آیا امکان طبقه‌بندی (Classifying) داده‌ها وجود دارد یا خیر. برای این کار با استفاده از **Classification Learner** متلب و دادن داده‌هایی که کلاس آن‌ها مشخص است، با مقدار **cross validation** های مختلف (که معادل نسبت تست و **train** های مختلف است) به روش **Linear SVM** داده‌ها را طبقه بندی کردیم. نتیجه این طبقه‌بندی نیز تنها به مقدار جزیی از حالت تصادفی (۱۶ درصد معادل احتمال  $\frac{1}{6}$  برای هر حالت خواب) فرق داشت و صحت آن حدود ۲۵ درصد شد! صفحه‌هایی که داده‌ها را جدا می‌کردند را نتوانستیم از خروجی **SVM** بگیریم که ارایه کنیم. ضمناً تلاش کردیم طبقه‌بندی را با صفحه‌های درجه سه و بالاتر انجام دهیم ولی مدت زمان اجرا بسیار طولانی شد و از آن صرف‌نظر کردیم.